

R para Economia

Lucas Mendes

24/03/2020

Modelos Cross - Section

Regressão Linear Simples

Lembra de sua aula de introdução à microeconomia? Tire seu livro do Mankiw do armário!

Agora pense que você irá analisar o mercado de **bananas**. Representando suas curvas de oferta e demanda

curva de demanda: $Y = \beta_d - \alpha_d X$

curva de oferta: $Y = \beta_o + \alpha_o X$

Regressão Linear Simples

Se considerarmos que $\beta_d = 80$ e $\beta_o = 10$ sendo que $\alpha_d = 4$ e $\alpha_o = 6$

- curva de demanda: $Y = 80 - 4X$

Regressão Linear Simples

Se considerarmos que $\beta_d = 80$ e $\beta_o = 10$ sendo que $\alpha_d = 4$ e $\alpha_o = 6$

- curva de demanda: $Y = 80 - 4X$
- curva de oferta: $Y = 10 + 6X$

Regressão Linear Simples

Temos como agora calcular o equilíbrio do mercado igualando a curva de demanda a curva de oferta

$$80 - 4X = 10 + 6X \quad (1)$$

$$70 = 10X \quad (2)$$

$$7 = X \quad (3)$$

Quandidade de equilíbrio = 7

Preço de equilíbrio = 52

Regressão Linear Simples

Isso foi o que você provavelmente fez em introdução a micro ou algo do tipo

So que nessa época, o seu professor te dava os valores de α e β

Agora você mesmo irá calculá-los!

Disclaimer

$$Y = \beta_1 + \beta_2 X$$

- O Y pode ser chamado de varios nomes, como variavel regressora, variavel dependente, variavel resposta e por ai vai.

Disclaimer

$$Y = \beta_1 + \beta_2 X$$

- O Y pode ser chamado de varios nomes, como variavel regressora, variavel dependente, variavel resposta e por ai vai.
- Porém eu irei chama - la de variavel **endógena**, ou seja, que é determinada pelo modelo.

Disclaimer

$$Y = \beta_1 + \beta_2 X$$

- O Y pode ser chamado de varios nomes, como variavel regressora, variavel dependente, variavel resposta e por ai vai.
- Porém eu irei chama - la de variavel **endógena**, ou seja, que é determinada pelo modelo.
- A mesma coisa vale para X , que tem varios nomes, mas eu chamarei de varável **exógena**.

Disclaimer

$$Y = \beta_1 + \beta_2 X$$

- O Y pode ser chamado de varios nomes, como variavel regressora, variavel dependente, variavel resposta e por ai vai.
- Porém eu irei chama - la de variavel **endógena**, ou seja, que é determinada pelo modelo.
- A mesma coisa vale para X , que tem varios nomes, mas eu chamarei de varável **exógena**.
- O que estiver no lado esquerdo da equação = **endógena**

Disclaimer

$$Y = \beta_1 + \beta_2 X$$

- O Y pode ser chamado de varios nomes, como variavel regressora, variavel dependente, variavel resposta e por ai vai.
- Porém eu irei chama - la de variavel **endógena**, ou seja, que é determinada pelo modelo.
- A mesma coisa vale para X , que tem varios nomes, mas eu chamarei de varável **exógena**.
- O que estiver no lado esquerdo da equação = **endógena**
- O que estiver no lado direito da equação = **exógena**

Regressão Linear Simples

Nesse capítulo iremos usar o pacote AER (Applied Econometrics with R) e o pacote caret (Machine Learning)

Cole no console e rode

```
# install.packages('AER')  
# install.packages('caret')
```

```
library(AER)  
library(caret)  
library(tidyverse)
```

Regressão Linear Simples

Iremos analisar agora a base de dados CPS1985, referente a pesquisa de determinação salarial feita em 1985 nos EUA.

Queremos verificar qual o impacto do total de anos de educação sobre o salário/hora de um indivíduo

Carregando o pacote

```
data('CPS1985')
```

Regressão Linear Simples

	wage	education	experience	age	ethnicity
1	5.10	8	21	35	hispanic
1100	4.95	9	42	57	cauc
2	6.67	12	1	19	cauc
3	4.00	12	4	22	cauc
4	7.50	12	17	35	cauc
5	13.07	13	9	28	cauc

Regressão Linear Simples

$$wage = \beta_1 + \beta_2 educ$$

Essa é nossa especificação da regressão, o código seguinte irá calcular os parâmetros β_1 e β_2

Regressão Linear Simples

Iremos agora treinar um modelo de regressão linear usando a função `train()` do pacote **caret**

```
modelo <- train(wage ~ # Variavel Exógena  
                education, # Variavel endógena  
                method = "lm", # Linear Model  
                data = CPS1985) # Base de dados
```

Regressão Linear Simples

Com o modelo criado, podemos observar as estatísticas usando o comando `summary()`.

```
summary(modelo)
```

Regressão Linear Simples

```
##
## Call:
## lm(formula = .outcome ~ ., data = dat)
##
## Residuals:
```

	Min	1Q	Median	3Q	Max
	-7.911	-3.260	-0.760	2.240	34.740

```
##
## Coefficients:
```

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	-0.74598	1.04545	-0.714	0.476
education	0.75046	0.07873	9.532	<2e-16 ***

```
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.754 on 532 degrees of freedom
```

Regressão Linear Simples

Eu particularmente não gosto muito do formato que o `summary` nos retorna. Como eu sigo a filosofia do tidyverse, eu transformo isso para um dataframe com a função `tidy()` do pacote `broom` (Já instalado com tidyverse)

```
library(broom)
summary(modelo) %>% tidy()
```

term	estimate	std.error	statistic	p.value
(Intercept)	-0.7459797	1.0454541	-0.7135461	0.4758208
education	0.7504608	0.0787337	9.5316300	0.0000000

Regressão Linear Simples

$$wage = -0.74 + educ0.75$$

O que podemos retirar do modelo e das estatísticas?

Normalmente olhamos para:

- O coeficiente das variáveis

Regressão Linear Simples

$$wage = -0.74 + educ0.75$$

O que podemos retirar do modelo e das estatísticas?

Normalmente olhamos para:

- O coeficiente das variáveis
- O valor t dessas variáveis

Regressão Linear Simples

$$wage = -0.74 + educ0.75$$

O que podemos retirar do modelo e das estatísticas?

Normalmente olhamos para:

- O coeficiente das variáveis
- O valor t dessas variáveis
- O R^2

Regressão Linear Simples

Coeficiente

- Quando analisamos o coeficiente de uma regressão, normalmente nós esperamos o seu sinal devido a uma teoria prévia.

Regressão Linear Simples

Coeficiente

- Quando analisamos o coeficiente de uma regressão, normalmente nós esperamos o seu sinal devido a uma teoria prévia.
- No nosso exemplo esperamos que seja positivo já que é um consenso que mais anos de estudo impactam positivamente no salário.

Regressão Linear Simples

Coeficiente

- Quando analisamos o coeficiente de uma regressão, normalmente nós esperamos o seu sinal devido a uma teoria prévia.
- No nosso exemplo esperamos que seja positivo já que é um consenso que mais anos de estudo impactam positivamente no salário.
- O que normalmente queremos testar é a magnitude do efeito de uma variável sobre a outra.

Regressão Linear Simples

Coeficiente

- Quando analisamos o coeficiente de uma regressão, normalmente nós esperamos o seu sinal devido a uma teoria prévia.
- No nosso exemplo esperamos que seja positivo já que é um consenso que mais anos de estudo impactam positivamente no salário.
- O que normalmente queremos testar é a magnitude do efeito de uma variável sobre a outra.
- O nosso modelo nos forneceu que β_2 era 0.75

Regressão Linear Simples

Coeficiente

- Quando analisamos o coeficiente de uma regressão, normalmente nós esperamos o seu sinal devido a uma teoria prévia.
- No nosso exemplo esperamos que seja positivo já que é um consenso que mais anos de estudo impactam positivamente no salário.
- O que normalmente queremos testar é a magnitude do efeito de uma variável sobre a outra.
- O nosso modelo nos forneceu que β_2 era 0.75
- A interpretação portanto é: Se um indivíduo estuda 1 ano a mais, ele ganha em média 0.75 centavos/hora a mais de salário

Regressão Linear Simples

Coeficiente

- Supondo que um indivíduo A estudou 10 anos

Regressão Linear Simples

Coeficiente

- Supondo que um indivíduo A estudou 10 anos
- $\text{Salário/hora} = -0.74 + 10 * 0.75 = 6.76$

Regressão Linear Simples

Coeficiente

- Supondo que um indivíduo A estudou 10 anos
- Salário/hora = $-0.74 + 10 * 0.75 = 6.76$
- Supondo que um individuo B estudou 11 anos

Regressão Linear Simples

Coeficiente

- Supondo que um indivíduo A estudou 10 anos
- Salario/hora = $-0.74 + 10 * 0.75 = 6.76$
- Supondo que um individuo B estudou 11 anos
- Salario/hora = $-0.74 + 11 * 0.75 = 7.51$

Regressão Linear Simples

Valor T

- O valor t é um valor que vem da formula $t = \frac{\beta}{EP(\beta)}$

Regressão Linear Simples

Valor T

- O valor t é um valor que vem da formula $t = \frac{\beta}{EP(\beta)}$
- Essa pequena conta é um teste estatístico que avalia se o nosso coeficiente β_i é diferente de zero.

Regressão Linear Simples

Valor T

- O valor t é um valor que vem da formula $t = \frac{\beta}{EP(\beta)}$
- Essa pequena conta é um teste estatístico que avalia se o nosso coeficiente β_i é diferente de zero.
- A regra de bolso que levamos é que se $t > |2|$, podemos rejeitar que o coeficiente é igual a zero.

Regressão Linear Simples

Valor T

- O valor t é um valor que vem da formula $t = \frac{\beta}{EP(\beta)}$
- Essa pequena conta é um teste estatístico que avalia se o nosso coeficiente β_i é diferente de zero.
- A regra de bolso que levamos é que se $t > |2|$, podemos rejeitar que o coeficiente é igual a zero.
- Vamos fazer a conta

Regressão Linear Simples

Valor T

term	estimate	std.error	statistic	p.value
(Intercept)	-0.7459797	1.0454541	-0.7135461	0.4758208
education	0.7504608	0.0787337	9.5316300	0.0000000

Regressão Linear Simples

R^2

- O R^2 mede o poder de explicação de uma regressão

Regressão Linear Simples

R^2

- O R^2 mede o poder de explicação de uma regressão
- Seus valores variam de 0 a 1.

Regressão Linear Simples

R^2

- O R^2 mede o poder de explicação de uma regressão
- Seus valores variam de 0 a 1.
- No nosso exemplo ele é 0.14, ou 14%

Regressão Linear Simples

R^2

- O R^2 mede o poder de explicação de uma regressão
- Seus valores variam de 0 a 1.
- No nosso exemplo ele é 0.14, ou 14%
- Muitos podem se enganar olhando apenas esse indicador, use o com cuidado.

Regressão Linear Simples

R^2

$$R^2 = \frac{SQE}{SQT}$$

$$SQR = SQT - SQE$$

SQT = Soma dos quadrados Totais SQE = Soma dos quadrados Explicados

SQR = Soma dos quadrados dos Resíduos

Regressão Linear Simples

R^2

```
summary(modelo) %>% glance()
```

r.squared	adj.r.squared	sigma	statistic	p.value	df
0.1458645	0.1442589	4.753987	90.85197	0	2

Exercicios

Elasticidades

Regressão Linear Simples (Elasticidades)

Talvez você já tenha ouvido falar sobre elasticidades, talvez até calculado na forma discreta.

Para calcular elasticidades, precisamos deixar as variáveis logarizadas usando a função `log()`

No nosso exemplo sobre educação, ficaria da seguinte maneira

```
modelo <- train(log(wage) ~ log(education),  
  method = "lm",  
  data = CPS1985)
```

Regressão Linear Simples (Elasticidades)

Observando as estatísticas

```
summary(modelo) %>% broom::tidy()
```

term	estimate	std.error	statistic	p.value
(Intercept)	0.0701300	0.2371804	0.2956821	0.7675883
log(education)	0.7822175	0.0928906	8.4208482	0.0000000

Regressão Linear Simples (Elasticidades)

$$\log(wage) = 0.07 + 0.78\log(educ)$$

- Agora a interpretação dos coeficientes muda um pouco.

Regressão Linear Simples (Elasticidades)

$$\log(wage) = 0.07 + 0.78\log(educ)$$

- Agora a interpretação dos coeficientes muda um pouco.
- Nós lemos da seguinte maneira:

Regressão Linear Simples (Elasticidades)

$$\log(wage) = 0.07 + 0.78\log(educ)$$

- Agora a interpretação dos coeficientes muda um pouco.
- Nós lemos da seguinte maneira:
- Se eu aumentar meus anos de estudo em 1%

Regressão Linear Simples (Elasticidades)

$$\log(wage) = 0.07 + 0.78\log(educ)$$

- Agora a interpretação dos coeficientes muda um pouco.
- Nós lemos da seguinte maneira:
- Se eu aumentar meus anos de estudo em 1%
- Meu salário/hora irá aumentar em média 0.78%

Regressão Linear Simples (Elasticidades)

$$\log(wage) = 0.07 + 0.78\log(educ)$$

- Agora a interpretação dos coeficientes muda um pouco.
- Nós lemos da seguinte maneira:
- Se eu aumentar meus anos de estudo em 1%
- Meu salário/hora irá aumentar em média 0.78%
- Todas as estatísticas seguem o mesmo procedimento de análise

Regressão Linear Simples (Elasticidades)

Logs

Logarizar os também serve para:

- Deixar relações exponenciais em lineares

$$y = x_1^{\beta_1} x_2^{\beta_2}$$

Se aplicarmos log


$$\log(y) = \beta_1 \log(x_1) + \beta_2 \log(x_2)$$

Cobb Douglas

Testando no R retornos de escala

```
cobb_douglas <- function(x1,x2,beta1 = 0.5,beta2 = 0.5){  
  x1^beta1 * x2^beta2  
}  
  
crescente <- cobb_douglas(seq(1:20),seq(1:20),beta1 = 1,beta2 = 1)  
constante <- cobb_douglas(seq(1:20),seq(1:20))  
decrescente <- cobb_douglas(seq(1:20),seq(1:20),beta1 = 0.3,beta2 = 0.3)
```

Cobb Douglas



Exercicios

Regressão Linear Multipla

Regressão Linear Múltipla

A regressão linear múltipla é quando estamos usando mais de uma variável endógena.

Exemplo

$$wage = \beta_1 + \beta_2 educ + \beta_3 experience$$

Regressão Linear Múltipla

Nós usamos a mesma função no R

```
modelo <- train(wage ~ education + experience,  
  method = "lm",  
  data = CPS1985)
```

Regressão Linear Multipla

```
summary(modelo) %>% broom::tidy()
```

term	estimate	std.error	statistic	p.value
(Intercept)	-4.9044823	1.2189240	-4.023616	6.56e-05
education	0.9259646	0.0814035	11.374999	0.00e+00
experience	0.1051316	0.0171975	6.113181	0.00e+00

Regressão Linear Multipla

$$wage = -4.9 + 0.92educ + 0.1exp$$

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar
- A estatística F é uma continha que testa se conjuntamente, há pelo menos um coeficiente diferente de zero.

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar
- A estatística F é uma continha que testa se conjuntamente, há pelo menos um coeficiente diferente de zero.
- Porém não há uma regra de bolso pois ele depende do graus de liberdade da regressão, então olhamos o valor - p por facilidade.

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar
- A estatística F é uma continha que testa se conjuntamente, há pelo menos um coeficiente diferente de zero.
- Porém não há uma regra de bolso pois ele depende do graus de liberdade da regressão, então olhamos o valor - p por facilidade.
- A regra de bolso do valor - p é, caso seja menor que 5%(0.05), sua regressão tem pelo menos um coeficiente diferente de zero.

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar
- A estatística F é uma continha que testa se conjuntamente, há pelo menos um coeficiente diferente de zero.
- Porém não há uma regra de bolso pois ele depende do graus de liberdade da regressão, então olhamos o valor - p por facilidade.
- A regra de bolso do valor - p é, caso seja menor que 5%(0.05), sua regressão tem pelo menos um coeficiente diferente de zero.
- O R^2 de uma regressão sempre irá crescer ou pelo menos ficar constante caso você acrescente uma variável endógena

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

- Além de todas as estatísticas que estudamos, agora temos mais três para analisar
- A estatística F é uma continha que testa se conjuntamente, há pelo menos um coeficiente diferente de zero.
- Porém não há uma regra de bolso pois ele depende do graus de liberdade da regressão, então olhamos o valor - p por facilidade.
- A regra de bolso do valor - p é, caso seja menor que 5%(0.05), sua regressão tem pelo menos um coeficiente diferente de zero.
- O R^2 de uma regressão sempre irá crescer ou pelo menos ficar constante caso você acrescente uma variável endógena
- Por isso, para compararmos regressões múltiplas, usamos o R^2 ajustado, que penaliza o incremento de variáveis que não ajudem o modelo a explicar melhor

Regressão Linear Múltipla

F-statistic, Valor - P e R^2 ajustado

```
summary(modelo) %>% broom::glance()
```

r.squared	adj.r.squared	sigma	statistic	p.value	df
0.2020248	0.1990192	4.599365	67.21709	0	3

Regressão com variáveis categóricas

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.
- Agora iremos ver como aplicar regressões com variáveis exógenas categóricas, na qual representam classes.

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.
- Agora iremos ver como aplicar regressões com variáveis exógenas categóricas, na qual representam classes.
- Para quem não sabe o que são as categóricas aqui em baixo vão dois exemplos:

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.
- Agora iremos ver como aplicar regressões com variáveis exógenas categóricas, na qual representam classes.
- Para quem não sabe o que são as categóricas aqui em baixo vão dois exemplos:
- Categóricas cardinais: Quando não há um ordenamento. Sexo (H,M)

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.
- Agora iremos ver como aplicar regressões com variáveis exógenas categóricas, na qual representam classes.
- Para quem não sabe o que são as categóricas aqui em baixo vão dois exemplos:
- Categóricas cardinais: Quando não há um ordenamento. Sexo (H,M)
- Categóricas ordinais: Quando há um ordenamento. Educação (Doutorado > Mestrado > Graduação)

Regressão com variáveis categóricas

- Até agora vimos regressões somente com variáveis endógenas contínuas e/ou discretas.
- Agora iremos ver como aplicar regressões com variáveis exógenas categóricas, na qual representam classes.
- Para quem não sabe o que são as categóricas aqui em baixo vão dois exemplos:
- Categóricas cardinais: Quando não há um ordenamento. Sexo (H,M)
- Categóricas ordinais: Quando há um ordenamento. Educação (Doutorado > Mestrado > Graduação)
- No R essas variáveis são da classe `factor`

Exercícios

Regressão com variáveis categóricas

```
# Gender é uma variavel categorica  
modelo <- train(wage ~ education + experience + gender,  
  method = "lm",  
  data = CPS1985)
```

Regressão com variáveis categóricas

```
summary(modelo) %>% broom::tidy()
```

term	estimate	std.error	statistic	p.value
(Intercept)	-4.1668750	1.1866703	-3.511401	0.0004838
education	0.9405066	0.0788634	11.925765	0.0000000
experience	0.1133003	0.0167082	6.781112	0.0000000
genderfemale	-2.3376324	0.3880624	-6.023857	0.0000000

Regressão com variáveis categóricas

$$wage = -4.16 + educ0.94 + exp0.11 - genderfemale2.33$$

Modelo Logístico

Modelo Logístico

O modelo de regressão logística também usa variáveis categóricas, so que agora endógenamente.

Ou seja, não queremos agora prever um possível número médio, mas sim uma classe como **sim** ou **não**.

Vamos pensar o contrário na nossa base de dados agora. Dado o salário/hora, anos de educação e experiencia conseguimos descobrir se a pessoa é do sexo masculino ou feminino?

Modelo Logístico

```
modelo <- train(gender ~ wage + education + experience,  
  method = "glm",  
  family = "binomial",  
  data = CPS1985)
```

Modelo Logístico

```
summary(modelo)
```

```
##
## Call:
## NULL
##
## Deviance Residuals:
##      Min       1Q   Median       3Q      Max
## -1.742  -1.085  -0.673   1.143   3.264
##
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -1.440471   0.572072  -2.518 0.011803 *
## wage        -0.134674   0.023724  -5.677 1.37e-08 ***
## education    0.148640   0.043049   3.453 0.000555 ***
## experience   0.029629   0.008334   3.555 0.000378 ***
##
```

Modelo Logístico

$$\textit{gender} = -1.44 - 0.13\textit{wage} + 0.14\textit{educ} + 0.02\textit{exp}$$

Modelo Logístico

Considerações sobre o modelo logístico

- A interpretação dos coeficientes são feitas em forma de probabilidade, e temos que passar a fórmula e^{β} para calculá-los

Modelo Logístico

Considerações sobre o modelo logístico

- A interpretação dos coeficientes são feitas em forma de probabilidade, e temos que passar a fórmula e^{β} para calculá-los
- O mesmo ocorre com a variável gender, que temos que passar a função $\frac{1}{1+e^{\gamma}}$

Modelo Logístico

Considerações sobre o modelo logístico

- A interpretação dos coeficientes são feitas em forma de probabilidade, e temos que passar a fórmula e^{β} para calculá-los
- O mesmo ocorre com a variável `gender`, que temos que passar a função $\frac{1}{1+e^{\gamma}}$
- Vamos calcular um exemplo

Modelo Logístico

Caso tivéssemos uma observação com as seguintes variáveis

wage = 5.1, educ = 8, exp = 21, qual seria a probabilidade dessa pessoa ser do gênero feminino

Jogando na fórmula

$$-1.44 - 0.13 * 5.1 + 0.14 * 8 + 0.02 * 21 = 0.76$$

Jogando agora na formula $\frac{1}{1+e^{(0.76)}} = 0.31$

A chance de ser do gênero feminino seria de 31%

Modelo Logístico

Agora para isso voltar como uma variável categórica nós precisamos definir um valor de decisão que varia entre 0 a 1.

- Na maioria dos casos esse valor é 0.5, ou seja.

Modelo Logístico

Agora para isso voltar como uma variável categórica nós precisamos definir um valor de decisão que varia entre 0 a 1.

- Na maioria dos casos esse valor é 0.5, ou seja.
- Se $\text{gender} > 0.5$, o indivíduo é do gênero feminino

Modelo Logístico

Agora para isso voltar como uma variável categórica nós precisamos definir um valor de decisão que varia entre 0 a 1.

- Na maioria dos casos esse valor é 0.5, ou seja.
- Se $\text{gender} > 0.5$, o indivíduo é do gênero feminino
- Se $\text{gender} < 0.5$, o indivíduo é do gênero masculino

Modelo Logístico

Podemos automatizar todo esse processo no R com a função `predict`, na qual nos retorna um vetor com a previsão de classificação do nosso data frame.

```
previsao <- predict(modelo, newdata = CPS1985)
previsao
```

```
##      [1] male    female male    male    male    male    female male
##     [11] male    male    male    male    male    female male    male
##     [21] female male    female female male    female male    female
##     [31] male    female male    female male    male    male    female
##     [41] male    male    male    male    female male    male    male
##     [51] male    male    male    female male    male    male    male
##     [61] male    male    male    male    male    male    male    male
##     [71] male    male    male    male    female female female male
##     [81] male    male    female female male    male    male    male
##     [91] male    male    male    female male    male    male    male
```

Modelo Logístico

Verificando a acurácia do modelo, usando uma matriz de confusão

```
table(previsao,CPS1985[, "gender"])
```

```
##  
## previsao male female  
##   male      218      115  
##   female    71      130
```

Essa matriz de confusão nos retorna diversos indicadores de acurácia do nosso modelo.

Para calcular a acurácia geral fazemos o seguinte: $(218 + 130) / 534 = 65\%$

Ou seja, nosso modelo acertou no geral 65% das classificações.

Para saber mais sobre essa matriz, clique aqui